
UNIVERSITY OF VERSAILLES SAINT-QUENTIN-EN-YVELINES
PARIS-SACLAY UNIVERSITY
Master's Degree in DataScale — Large-Scale Data Management

M2 Internship Notes : L'explicabilité des predictions des modeles GNNs

PREPARED BY
FIDÈLE OUEDRAOGO

SUPERVISORS
Prof. CHRISTINE LARGERON
Dr. HAIFEI ZHANG

DATE
7 March 2026

Hubert Curien Laboratory
2025–2026

Contents

1	Méthodes classiques d’explicabilité des réseaux de neurones	3
1.1	Principales familles de méthodes d’explicabilité	3
1.2	Limites des méthodes classiques sur les données graphes	3
2	Méthodes d’explicabilité dédiées aux Graph Neural Networks	4
2.1	GNNE explainer : une méthode d’explicabilité locale indépendante du modèle	4
2.2	Fondements théoriques de GNNE explainer	5
2.2.1	Du graphe de calcul au sous-graphe explicatif	5
2.2.2	Formulation par maximisation de l’information mutuelle	7
2.2.3	Approximation continue par masque différentiable	10
2.2.4	Objectif de substitution optimisé par descente de gradient	11
2.2.5	Apprentissage conjoint du masque structurel et du masque de caractéristiques	12
2.2.6	Explications multi-instances par prototype de graphe	13

Introduction

Les notes portent notamment sur les méthodes d'explicabilité locales et globales, les limites des approches classiques d'interprétabilité développées pour les réseaux de neurones conventionnels, ainsi que les méthodes spécifiquement conçues pour expliquer les prédictions des GNNs. Une attention particulière est accordée aux motivations théoriques, aux formulations d'optimisation et aux approximations utilisées afin de relier les principes mathématiques aux implémentations pratiques.

Chapter 1

Méthodes classiques d'explicabilité des réseaux de neurones

1.1 Principales familles de méthodes d'explicabilité

Les premières méthodes d'explicabilité ont été développées pour des réseaux de neurones opérant sur des données euclidiennes telles que les images, le texte ou les séries temporelles. De manière générale, ces approches se répartissent en deux grandes familles :

- les méthodes basées sur des modèles substitués (*surrogate models*) ;
- les méthodes basées sur les gradients et l'analyse interne du réseau.

Les sections suivantes présentent le principe général de chacune de ces familles ainsi que leurs domaines d'application.

1.2 Limites des méthodes classiques sur les données graphes

Les méthodes précédentes supposent généralement que les caractéristiques d'entrée sont indépendantes ou possèdent une structure spatiale régulière, comme les pixels d'une image ou les mots d'une phrase. Cette hypothèse n'est plus vérifiée dans les graphes, où la prédiction dépend conjointement des caractéristiques des nœuds et des relations topologiques entre eux.

Dans un graphe, l'importance d'une arête ou d'un nœud ne peut généralement pas être évaluée indépendamment des autres éléments du voisinage. Une structure particulière (cycle, motif, chemin, etc.) peut être déterminante pour une prédiction alors qu'aucune de ses composantes, prise isolément, ne possède une contribution significative. Cette dépendance structurelle limite directement l'utilisation des méthodes d'explicabilité classiques sur les Graph Neural Networks.

Chapter 2

Méthodes d’explicabilité dédiées aux Graph Neural Networks

Les limites des méthodes classiques ont conduit au développement d’approches spécifiquement conçues pour expliquer les prédictions des Graph Neural Networks. Selon le niveau d’explication recherché, ces méthodes peuvent être classées en deux grandes catégories :

- les méthodes d’explicabilité locale, qui expliquent une prédiction particulière ;
- les méthodes d’explicabilité globale, qui cherchent à expliquer le comportement général d’un modèle ou d’une classe entière de prédictions.

Cette distinction servira de fil conducteur pour l’étude des différentes méthodes présentées dans les chapitres suivants.

2.1 GNNExplainer : une méthode d’explicabilité locale indépendante du modèle

GNNExplainer, proposé par Ying et al. (NeurIPS 2019), constitue la première méthode générale permettant d’expliquer les prédictions des Graph Neural Networks. Il s’agit d’une méthode *post-hoc* et *model-agnostic*, c’est-à-dire qu’elle peut être appliquée à tout modèle de GNN déjà entraîné sans dépendre de son architecture interne (GCN, GAT, GraphSAGE, GIN, etc.).

L’objectif de GNNExplainer est d’identifier les éléments du graphe qui influencent le plus une prédiction donnée. Plus précisément, la méthode recherche un sous-graphe explicatif extrait du graphe de calcul (*computation graph*) ainsi qu’un sous-ensemble des caractéristiques des nœuds responsables de la décision du modèle.

GNNExplainer distingue deux niveaux d’explication :

- **Explication d’une seule instance (*single-instance explanation*)** : expliquer une prédiction individuelle correspondant à un nœud, un lien ou un graphe.

- **Explication de plusieurs instances (*multi-instance explanation*)** : agréger plusieurs explications locales afin d'extraire un prototype représentatif d'une classe ou d'un ensemble de prédictions, constituant ainsi une première forme d'explicabilité globale.

2.2 Fondements théoriques de GNNExplainer

2.2.1 Du graphe de calcul au sous-graphe explicatif

Soit un graphe d'entrée :

$$G = (V, E, X)$$

où :

- V représente l'ensemble des nœuds ;
- E représente l'ensemble des arêtes ;
- $X \in \mathbb{R}^{|V| \times d}$ représente les caractéristiques des nœuds.

Un modèle GNN entraîné est représenté par une fonction :

$$\Phi(G, X)$$

qui produit une prédiction :

$$\hat{Y} = \Phi(G, X)$$

Selon la tâche considérée, cette prédiction peut correspondre à :

- la classe d'un nœud (*node classification*) ;
- l'existence d'une relation entre deux nœuds (*link prediction*) ;
- la classe d'un graphe entier (*graph classification*).

Graphe de calcul (*computation graph*)

Lorsqu'un GNN produit une prédiction pour une instance donnée, il n'utilise généralement pas l'ensemble du graphe d'entrée. La partie effectivement impliquée dans le calcul de cette prédiction est appelée :

$$G_c$$

ou *graphe de calcul*.

Le graphe de calcul dépend principalement :

- de l'architecture du GNN ;

- du nombre de couches de propagation de messages ;
- de la stratégie d'échantillonnage éventuelle des voisins.

Par exemple, pour un GNN possédant K couches de convolution de graphe, la représentation finale d'un nœud v_i dépend généralement de son voisinage jusqu'à une distance K :

$$h_i^{(K)} = f \left(\{h_j^{(0)}, j \in N_K(i)\} \right)$$

où $N_K(i)$ représente l'ensemble des nœuds accessibles depuis v_i en au plus K sauts.

Ainsi, le calcul de la prédiction :

$$\hat{y}_i = \Phi(G_c, X_c)$$

est réalisé uniquement à partir du graphe de calcul associé au nœud v_i .

Objectif de GNNExplainer

Le graphe de calcul G_c contient généralement des informations pertinentes et non pertinentes pour la prédiction.

L'objectif de GNNExplainer est d'identifier une partie minimale de G_c contenant uniquement les éléments nécessaires à la décision du modèle.

On cherche donc un sous-graphe explicatif :

$$G_S \subseteq G_c$$

ainsi qu'un sous-ensemble des caractéristiques associées :

$$X_S = \{x_j | v_j \in G_S\}$$

Le sous-graphe G_S doit satisfaire deux propriétés :

1. conserver l'information nécessaire pour reproduire la prédiction du modèle ;
2. être suffisamment compact afin d'obtenir une explication interprétable.

La relation entre les différentes structures est donc :

$$\boxed{G_S \subseteq G_c \subseteq G}$$

où :

- G : graphe complet du problème ;
- G_c : sous-graphe utilisé par le GNN pour produire une prédiction ;
- G_S : sous-graphe explicatif recherché par GNNExplainer.

Principe intuitif

Le GNN effectue une agrégation de messages provenant du graphe de calcul :

$$m_i^{(k)} = AGGREGATE \left(\{h_j^{(k-1)}, j \in N(i)\} \right)$$

puis met à jour la représentation du nœud :

$$h_i^{(k)} = UPDATE \left(h_i^{(k-1)}, m_i^{(k)} \right)$$

Cependant, tous les messages agrégés ne contribuent pas nécessairement à la prédiction finale.

GNNEExplainer cherche donc les chemins de propagation de messages et les caractéristiques des nœuds ayant la contribution la plus importante :

$$G_c \longrightarrow G_S$$

où G_S représente la structure minimale permettant de conserver la prédiction :

$$\Phi(G_S, X_S) \approx \Phi(G_c, X_c)$$

La question centrale devient alors :

Quel sous-graphe G_S maximise l'information contenue sur la prédiction du GNN ?

Cette question conduit naturellement à la formulation par information mutuelle présentée dans la section suivante.

2.2.2 Formulation par maximisation de l'information mutuelle

Après avoir défini le graphe de calcul G_c et le sous-graphe explicatif G_S , l'objectif de GNNEExplainer consiste à rechercher la partie du graphe qui contient le maximum d'information nécessaire pour expliquer la prédiction du modèle.

Cette notion d'importance est formulée à l'aide de l'information mutuelle (*Mutual Information*).

Définition de l'information mutuelle

L'information mutuelle mesure la quantité d'information partagée entre deux variables aléatoires. Elle permet d'évaluer dans quelle mesure la connaissance d'une variable réduit

l'incertitude sur une autre variable.

Pour deux variables aléatoires A et B , l'information mutuelle est définie par :

$$MI(A, B) = H(A) - H(A|B)$$

où :

- $H(A)$ représente l'entropie de Shannon de A ;
- $H(A|B)$ représente l'entropie conditionnelle de A sachant B .

Dans le contexte de GNNExplainer :

$$A = Y$$

représente la sortie du modèle GNN, c'est-à-dire la distribution des labels prédits, et :

$$B = (G_S, X_S)$$

représente l'explication composée du sous-graphe sélectionné et des caractéristiques associées.

Ainsi, l'information mutuelle devient :

$$MI(Y, (G_S, X_S)) = H(Y) - H(Y|G_S, X_S)$$

Objectif d'optimisation de GNNExplainer

GNNExplainer cherche le sous-graphe G_S qui maximise l'information mutuelle entre l'explication et la prédiction du modèle :

$$\max_{G_S} MI(Y, (G_S, X_S)) = H(Y) - H(Y|G = G_S, X = X_S)$$

Cette formulation signifie que le sous-graphe explicatif doit satisfaire la propriété suivante :

$$(G_S, X_S) \rightarrow \hat{Y}$$

c'est-à-dire que la connaissance du sous-graphe explicatif doit permettre de retrouver avec précision la prédiction du modèle.

Interprétation des différents termes

Le terme :

$$H(Y)$$

représente l'incertitude globale associée aux prédictions du modèle.

Comme le modèle GNN Φ est déjà entraîné et fixé, cette quantité reste constante pendant l'optimisation.

Le terme :

$$H(Y|G = G_S, X = X_S)$$

représente l'incertitude restante sur la prédiction lorsque le modèle est limité uniquement au sous-graphe explicatif G_S et aux caractéristiques X_S .

Ainsi :

- si G_S contient les informations essentielles, alors

$$H(Y|G_S, X_S) \rightarrow 0$$

et la prédiction reste certaine ;

- si G_S contient peu d'informations utiles, alors

$$H(Y|G_S, X_S)$$

reste élevée.

L'explication optimale correspond donc au sous-graphe qui réduit au maximum l'incertitude sur la prédiction.

Relation avec la prédiction du GNN

Soit une prédiction initiale :

$$\hat{y}_i = \Phi(G_c, X_c)$$

produite pour un nœud v_i .

GNNExpainer cherche un sous-graphe :

$$G_S \subseteq G_c$$

tel que :

$$P_\Phi(Y = \hat{y}_i | G = G_S, X = X_S)$$

reste maximale.

Autrement dit, après suppression des éléments non importants du graphe de calcul, le modèle doit conserver une forte probabilité pour la même classe prédite.

On peut donc interpréter l'objectif de GNNExplainer comme :

Trouver le plus petit sous-graphe conservant la prédiction du GNN

Cependant, cette formulation possède une difficulté majeure : le sous-graphe G_S est une structure discrète. La recherche directe parmi tous les sous-graphes possibles de G_c est donc impossible en pratique. Cette problématique conduit à la reformulation en terme d'entropie conditionnelle, puis à l'introduction d'une approximation continue par masque différentiable.

2.2.3 Approximation continue par masque différentiable

La formulation précédente conduit à un problème d'optimisation sur un sous-graphe G_S . Cependant, la recherche directe de G_S est difficile car un graphe possède un nombre exponentiel de sous-graphes possibles.

De plus, la sélection d'une arête est une opération discrète :

$$A_{ij} \in \{0, 1\}$$

ce qui empêche l'utilisation directe des méthodes d'optimisation par gradient.

Pour rendre le problème différentiable, GNNExplainer introduit une relaxation continue sous la forme d'un masque appris sur les arêtes.

Soit :

$$M \in \mathbb{R}^{n \times n}$$

la matrice de masque où chaque élément M_{ij} représente l'importance de l'arête (v_i, v_j) .

Une fonction sigmoïde est appliquée afin de transformer les valeurs du masque dans l'intervalle $[0, 1]$:

$$\sigma(M) = \frac{1}{1 + e^{-M}}$$

Chaque valeur :

$$\sigma(M_{ij})$$

représente alors le poids associé à l'arête correspondante.

Le graphe de calcul masqué est obtenu par :

$$A_S = A_c \odot \sigma(M)$$

où :

- A_c est la matrice d'adjacence du graphe de calcul ;
- $\odot$ représente le produit terme à terme (produit de Hadamard) ;
- $\sigma(M)$ est le masque différentiable appris.

Ainsi, les arêtes importantes obtiennent des valeurs proches de 1, tandis que les arêtes peu utiles obtiennent des valeurs proches de 0.

Le problème initial devient alors l'apprentissage d'un masque continu :

$$\min_M H(Y|G = A_c \odot \sigma(M), X = X_c)$$

Après optimisation, les faibles valeurs du masque sont supprimées par seuillage afin d'obtenir le sous-graphe explicatif final :

$$G_S \subseteq G_c.$$

2.2.4 Objectif de substitution optimisé par descente de gradient

L'entropie conditionnelle constitue la formulation théorique de GNNExplainer. Cependant, son optimisation directe reste difficile en pratique.

Les auteurs introduisent donc un objectif de substitution (*surrogate objective*) basé sur la cross-entropie, qui permet une optimisation efficace par descente de gradient.

Pour une prédiction dont la classe correcte est y , l'objectif devient :

$$\min_M - \sum_{c=1}^C \mathbf{1}[y = c] \log P_{\Phi}(Y = c | G = A_c \odot \sigma(M), X = X_c)$$

Cette fonction correspond à la cross-entropie entre :

- le label réel y ;
- la distribution de probabilité produite par le GNN après application du masque.

Le principe est le suivant :

$$A_c \odot \sigma(M) \rightarrow \Phi \rightarrow P_{\Phi}(Y)$$

Le gradient de la fonction de perte indique quelles valeurs du masque doivent être augmentées ou diminuées afin de conserver la prédiction initiale.

Après convergence :

$$\sigma(M_{ij}) \approx 1$$

indique une arête importante pour la prédiction, tandis que :

$$\sigma(M_{ij}) \approx 0$$

indique une arête peu informative.

Le sous-graphe explicatif final est obtenu en conservant uniquement les éléments ayant les scores d'importance les plus élevés.

Ainsi, GNNExplainer transforme un problème discret de recherche de sous-graphe optimal en un problème continu d'apprentissage de masque, résolu efficacement par optimisation gradient.

2.2.5 Apprentissage conjoint du masque structurel et du masque de caractéristiques

Jusqu'à présent, GNNExplainer apprend un masque structurel M permettant d'identifier les arêtes importantes du graphe de calcul. Les auteurs étendent ensuite cette approche afin d'identifier également les dimensions des caractéristiques des nœuds les plus influentes dans la prédiction.

Un masque binaire de caractéristiques est introduit :

$$F \in \{0, 1\}^d$$

où d est le nombre de caractéristiques par nœud.

Pour chaque nœud $v_j \in G_S$, seules les caractéristiques sélectionnées par F sont conservées :

$$X_S^F = \{x_j^F \mid v_j \in G_S\}$$

avec

$$x_j^F = [x_{j,t_1}, \dots, x_{j,t_k}] \quad \text{pour } F_{t_i} = 1.$$

L'objectif devient alors d'apprendre simultanément le sous-graphe explicatif et le masque de caractéristiques :

$$\max_{G_S, F} MI(Y, (G_S, F)) = H(Y) - H(Y|G = G_S, X = X_S^F)$$

L'explication finale dépend ainsi à la fois :

$$(G_S, X_S^F)$$

c'est-à-dire :

- du sous-graphe explicatif ;
- des caractéristiques importantes des nœuds de ce sous-graphe.

Reparamétrisation du masque de caractéristiques

Le masque F étant discret, son apprentissage direct par descente de gradient n'est pas possible.

Les auteurs utilisent une reparamétrisation :

$$X = Z + (X_S - Z)F$$

sous la contrainte

$$\sum_j F_j \leq K_F$$

où :

- Z est une variable aléatoire échantillonnée depuis la distribution empirique ;
- K_F représente le nombre maximal de caractéristiques conservées dans l'explication.

Cette formulation permet de propager les gradients jusqu'au masque F tout en apprenant automatiquement les caractéristiques les plus importantes pour la prédiction.

2.2.6 Explications multi-instances par prototype de graphe

Les sections précédentes permettent d'obtenir une explication **locale**, c'est-à-dire le sous-graphe explicatif associé à une seule prédiction :

$$v_i \longrightarrow G_S(v_i).$$

Pour expliquer un ensemble de prédictions appartenant à une même classe c , GNNExplainer agrège plusieurs explications locales afin de construire un **prototype de graphe** représentant les motifs structurels communs à cette classe.

Les explications locales des différents nœuds sont d'abord alignées afin de mettre en correspondance leurs structures de graphe. Un graphe explicatif de référence peut être utilisé comme repère pour faciliter cet alignement.

Après alignement, les matrices d'adjacence des sous-graphes explicatifs sont agrégées afin d'obtenir le prototype :

$$A_{\text{proto}} = \text{Aggregate} \left(A_{G_S(v_1)}, A_{G_S(v_2)}, \dots, A_{G_S(v_n)} \right)$$

où l'agrégation peut être réalisée à l'aide d'une médiane robuste.

Le prototype :

$$A_{\text{proto}}$$

représente les structures de graphe communes aux nœuds appartenant à une même classe et constitue l'**explication multi-instance**. Il permet de comparer l'explication locale d'un nœud particulier avec le comportement général de sa classe.

Bibliography